Predicción del Abandono y Éxito Académico mediante Técnicas de Machine Learning

Aplicación de modelos predictivos para la identificación temprana del riesgo de deserción estudiantil.

Proyecto de Ciencia de Datos Aplicada e Inteligencia Artificial

Autora:
Yimari Acosta Castro

Programa Académico:
Ingeniería de Sistemas

Área de Investigación:

Ciencia de Datos • Inteligencia Artificial • Analítica Predictiva Educativa

Tipo de Proyecto:

Proyecto de Investigación Aplicada en Machine Learning

Institución de Formación:

Corporación Universitaria Rafel Núñez

Colombia, Cartagena, Bolívar

2026

Abstract

Student dropout represents one of the main challenges faced by modern educational systems, affecting both students' academic development and institutional efficiency (Tinto, 2012). This project aims to develop a predictive model based on Artificial Intelligence and Machine Learning techniques capable of identifying patterns associated with academic dropout, student retention, and graduation outcomes.

A structured academic dataset containing demographic, socioeconomic, and academic performance variables was used for this study. Data preprocessing techniques, exploratory data analysis, and feature selection processes were applied to improve model performance and ensure data quality.

The models were evaluated using performance metrics such as accuracy, achieving an approximate predictive performance of 75%, demonstrating the feasibility of applying Artificial Intelligence for early academic risk detection. The social impact of this project lies in enabling educational institutions to anticipate potential dropout cases, facilitating the implementation of data-driven academic support strategies and student assistance programs.This work highlights how the integration of Data Science and Artificial Intelligence can directly contribute to improving educational quality and supporting intelligent institutional decision-making.

1. Introducción

La deserción estudiantil representa uno de los principales desafíos que enfrentan las instituciones de educación superior, ya que afecta tanto el desarrollo académico de los estudiantes como la eficiencia de los sistemas educativos. En los últimos años, el uso de técnicas de análisis de datos ha permitido identificar patrones en el comportamiento académico de los estudiantes con el fin de anticipar posibles casos de abandono (Romero & Ventura, 2010).

El desarrollo de técnicas de aprendizaje automático ha permitido analizar grandes volúmenes de información educativa para generar modelos predictivos que apoyen la toma de decisiones dentro de las instituciones académicas (Mitchell, 1997).

En este proyecto se desarrolló un sistema de análisis de datos utilizando el lenguaje de programación Python en el entorno Google Colab. El objetivo principal fue analizar un conjunto de datos relacionado con el desempeño académico de estudiantes y construir un modelo capaz de clasificar su estado académico en tres posibles categorías: Graduate, Dropout (deserción) y Enrolled (matriculado).

Para ello se utilizaron herramientas especializadas como Pandas para la manipulación de datos, Scikit-learn para la construcción del modelo predictivo y Matplotlib para la visualización de resultados (Witten et al., 2016).

2. Planteamiento del Problema

Las instituciones educativas enfrentan dificultades para identificar estudiantes en riesgo de abandonar sus estudios. La ausencia de herramientas analíticas limita la implementación de estrategias preventivas efectivas.

Por lo tanto, se plantea la siguiente pregunta de investigación:

¿Es posible utilizar técnicas de aprendizaje automático para predecir el estado académico de los estudiantes a partir de variables de su historial educativo y socioeconómico?

3. Objetivo General

Desarrollar un modelo predictivo basado en técnicas de Machine Learning que permita identificar estudiantes con riesgo de abandono o bajo rendimiento académico, utilizando datos históricos y variables académicas relevantes.

Objetivos Específicos

- Explorar y limpiar el conjunto de datos.
- Analizar la distribución de las variables.
- Construir y entrenar un modelo de clasificación basado en Random Forest.
- Evaluar el desempeño del modelo con métricas y gráficas.
- Generar evidencia visual y estadística para apoyar la investigación.

4. Marco Teórico

La deserción estudiantil es un fenómeno que afecta significativamente a las instituciones de educación superior, ya que implica la interrupción del proceso académico por parte del estudiante antes de completar su programa de formación. Este fenómeno puede estar asociado a diversos factores de carácter académico, económico, social y personal, los cuales influyen en la permanencia y éxito académico de los estudiantes. Según Tinto (2012), la deserción universitaria es el resultado de un proceso complejo en el que intervienen múltiples variables relacionadas con el desempeño académico, la integración institucional y las condiciones socioeconómicas del estudiante.

En los últimos años, el avance de la tecnología y el crecimiento de los sistemas de información académica han permitido que las instituciones educativas generen grandes volúmenes de datos sobre el comportamiento de los estudiantes. Estos datos incluyen información sobre rendimiento académico, matrícula, historial de cursos, asistencia y otros indicadores relevantes. La disponibilidad de estos datos ha impulsado el desarrollo de la analítica del aprendizaje (Learning Analytics) y la minería de datos educativos, disciplinas que buscan analizar información educativa con el fin de mejorar los procesos de enseñanza y aprendizaje (Romero & Ventura, 2010).

Dentro de este contexto, el aprendizaje automático (Machine Learning) se ha convertido en una herramienta fundamental para analizar datos educativos y construir modelos predictivos que permitan anticipar comportamientos académicos. El aprendizaje automático consiste en un conjunto de técnicas que permiten a los sistemas informáticos aprender patrones a partir de los datos y realizar predicciones o clasificaciones sin ser programados explícitamente para cada situación (Mitchell, 1997).

Uno de los algoritmos más utilizados en problemas de clasificación es Random Forest, el cual se basa en la construcción de múltiples árboles de decisión que trabajan de manera conjunta para mejorar la precisión de las predicciones. Este algoritmo permite manejar grandes volúmenes de datos, reducir el riesgo de sobreajuste y mejorar la capacidad de generalización del modelo (Breiman, 2001).

En el ámbito educativo, diversos estudios han demostrado que los modelos de aprendizaje automático pueden ser utilizados para predecir el abandono estudiantil a partir de variables relacionadas con el rendimiento académico, las características socioeconómicas y el comportamiento del estudiante durante su proceso de formación. La identificación temprana de estudiantes en riesgo permite a las instituciones implementar estrategias de apoyo académico y acompañamiento que contribuyan a mejorar la permanencia estudiantil (Baker & Inventado, 2014).

Con base en estos fundamentos teóricos, el presente proyecto propone el desarrollo de un modelo predictivo basado en técnicas de Machine Learning que permita analizar información académica y predecir el estado de los estudiantes, clasificándolos en categorías como graduado, desertor o estudiante activo. Para ello se emplean herramientas de análisis de datos como Pandas para el procesamiento de la información, Scikit-learn para la construcción del modelo predictivo y Matplotlib para la visualización de resultados, siguiendo un enfoque metodológico orientado al análisis exploratorio de datos, entrenamiento del modelo y evaluación de su desempeño.

5. Metodología

El proceso de análisis de datos y construcción del modelo predictivo sigue las etapas comunes utilizadas en proyectos de minería de datos, las cuales incluyen la exploración de datos, el preprocesamiento, el entrenamiento del modelo y la evaluación de resultados (Witten, Frank, Hall & Pal, 2016).

5.1 Carga y limpieza del dataset

Se utilizó Pandas para cargar el dataset `data.csv` y se especificó el separador correcto (`;`). También se limpiaron los nombres de las columnas para eliminar espacios.

```
import pandas as pd

data = pd.read_csv("data.csv", sep=";")

data.head()
```

Se muestran solo las primeras 10 columnas, el dataset completo tiene 37 columnas.

```
# Mostrar solo primeras 10 columnas

display(data.iloc[:, :10].head())
```

	Marital status	Application mode	Application order	Course	Daytime/evening attendance	Previous qualification	Previous qualification (grade)	Nacionality	Mother's qualification	Father's qualification
0	1	17	5	171	1	1	122.0	1	19	12
1	1	15	1	9254	1	1	160.0	1	1	3
2	1	1	5	9070	1	1	122.0	1	37	37
3	1	17	2	9773	1	1	122.0	1	38	37
4	2	39	1	8014	0	1	100.0	1	37	38

Figura 1: *Primeras filas del dataset.*

Descripción del dataset

El dataset utilizado contiene información académica y socioeconómica de estudiantes universitarios. Este conjunto de datos incluye variables relacionadas con el rendimiento académico, características personales y condiciones económicas que pueden influir en la permanencia o abandono de los estudios. El conjunto de datos ha sido utilizado en investigaciones relacionadas con la predicción del rendimiento académico en educación superior (Martins et al., 2021).

Variables relevantes:

Estado civil → Marital status

Modalidad de ingreso → Application mode

Orden de aplicación → Application order

Curso → Course

Calificación de admisión → Admission grade

Edad al momento de matrícula → Age at enrollment

Unemployment rate, Inflation rate, GDP → variables económicas

5.2 Exploración de los datos (EDA)

Se realizó un análisis exploratorio para comprender la estructura del dataset, detectar valores nulos y revisar la distribución de la variable objetivo.

La mayoría de los estudiantes del dataset corresponden a la categoría *Graduate*, seguida por *Dropout* y finalmente *Enrolled*, lo cual evidencia un desbalance moderado entre las clases.

```
tabla_target = data['Target'].value_counts().reset_index()
tabla_target.columns = ['Estado académico', 'Cantidad']

display(tabla_target)
```

	Estado académico	Cantidad
0	Graduate	2209
1	Dropout	1421
2	Enrolled	794

Tabla 1. *Distribución del estado académico de los estudiantes*

La variable objetivo del modelo corresponde a **Target**, la cual clasifica el estado académico del estudiante en tres categorías:

Graduate → estudiante que se graduó

Dropout → estudiante que abandonó

Enrolled → estudiante que sigue estudiando

Se observa que la categoría con mayor número de registros corresponde a los estudiantes graduados (*Graduate*), seguida por aquellos que abandonaron sus estudios (*Dropout*) y finalmente los estudiantes que continúan matriculados (*Enrolled*). Este análisis permite comprender el comportamiento general de los datos y verificar el balance de clases previo al proceso de entrenamiento del modelo de predicción.

```
import matplotlib.pyplot as plt

data['Target'].value_counts().plot(kind='bar')
```

```
plt.title('Distribución del estado académico de los estudiantes')

plt.xlabel('Estado del estudiante')

plt.ylabel('Cantidad de estudiantes')

plt.show()
```

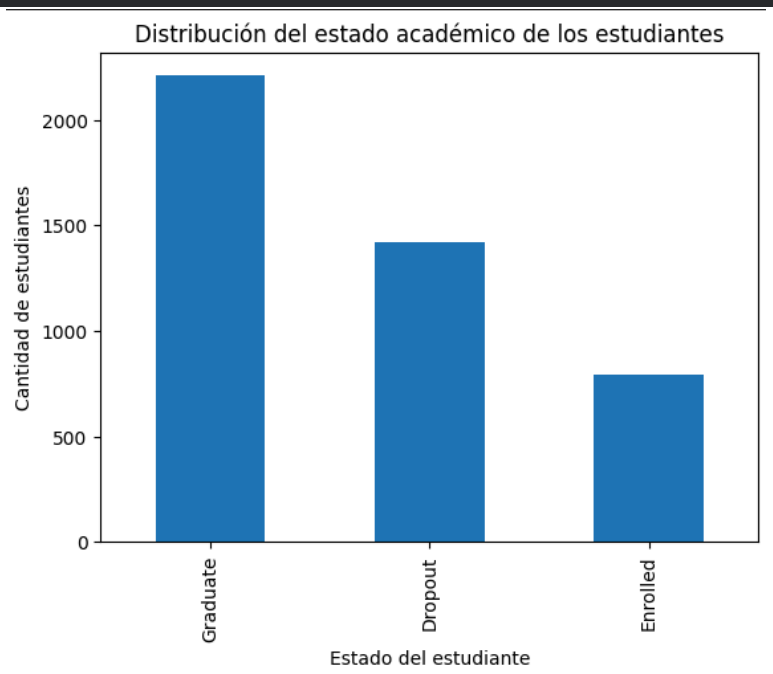

Figura 1. *Distribución del estado académico de los estudiantes en el conjunto de datos.*

```
import matplotlib.pyplot as plt

import seaborn as sns

plt.figure(figsize=(6,4))

sns.countplot(x='Target', data=data, palette='Set2')

plt.title("Distribución del estado académico de los estudiantes")

plt.ylabel("Cantidad de estudiantes")

plt.xlabel("Estado académico")

plt.show()
```

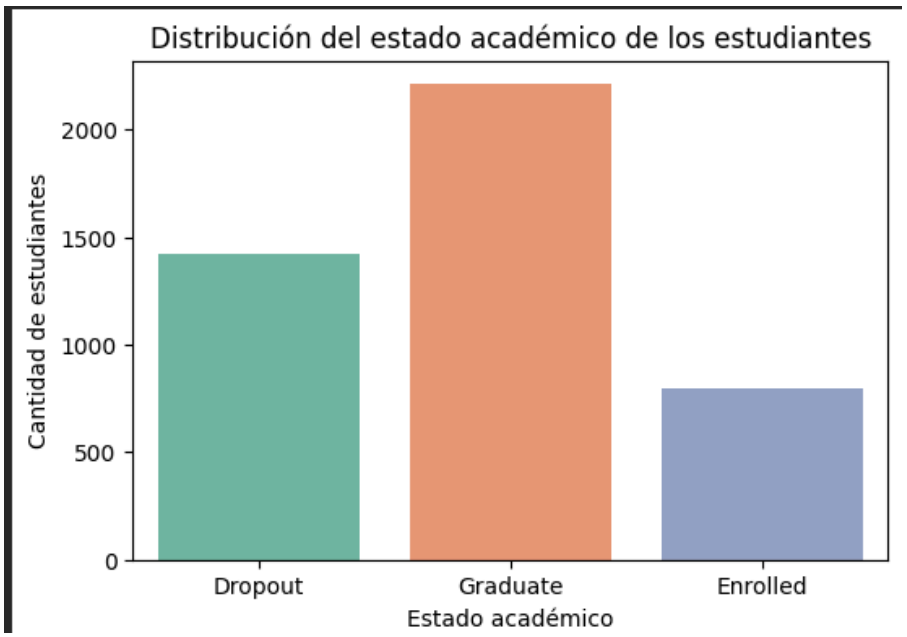

Figura 2: *Gráfica de distribución de estudiantes según su estado académico.*

5.3 Preparación de variables

Posteriormente se realizó el preprocesamiento de los datos, el cual consistió en separar las variables predictoras (X) de la variable objetivo (**y**), lo cual permitió preparar los datos para el entrenamiento del modelo de aprendizaje automático.

```
target_col = 'Target'

X = data.drop(target_col, axis=1)

y = data[target_col]
```

Luego se dividió el dataset en entrenamiento y prueba:

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(

    X, y, test_size=0.2, random_state=42

)
```

Con el fin de evaluar adecuadamente el desempeño del modelo, el dataset fue dividido en dos subconjuntos:

- **Datos de entrenamiento (Training set)**: utilizados para entrenar el modelo.

- **Datos de prueba (Test set)**: utilizados para evaluar el rendimiento del modelo.

Esta división se realizó utilizando la función train_test_split de la librería Scikit-learn, lo cual permite evitar problemas de sobreajuste y evaluar la capacidad de generalización del modelo.

5.4 Entrenamiento del modelo

Se entrenó un Random Forest Classifier, un modelo robusto para clasificación de múltiples clases.

El modelo fue entrenado utilizando los datos de entrenamiento, permitiendo que el algoritmo identifique patrones dentro del conjunto de datos y aprenda relaciones entre las variables académicas y el estado final del estudiante.

```
from sklearn.ensemble import RandomForestClassifier

modelo = RandomForestClassifier(random_state=42)

modelo.fit(X_train, y_train)
```

5.5 Evaluación del modelo

Una vez entrenado el modelo, se realizaron predicciones utilizando los datos de prueba con el fin de evaluar su desempeño. Para ello se utilizó una **matriz de confusión**, la cual permite comparar las predicciones del modelo con los valores reales del dataset.

```
from sklearn.metrics import confusion_matrix, classification_report, accuracy_score

predicciones = modelo.predict(X_test)

accuracy = accuracy_score(y_test, predicciones)
print(f"Precisión del modelo: {accuracy:.2f}")

cm = confusion_matrix(y_test, predicciones)
print(cm)
```

```
Precisión del modelo: 0.76
[[243  23  50]
 [ 35  45  71]
 [  9  24 385]]
```

La matriz de confusión permite identificar:

- Predicciones correctas del modelo.

- Posibles errores de clasificación.

- Capacidad del modelo para distinguir entre estudiantes graduados, activos o desertores.

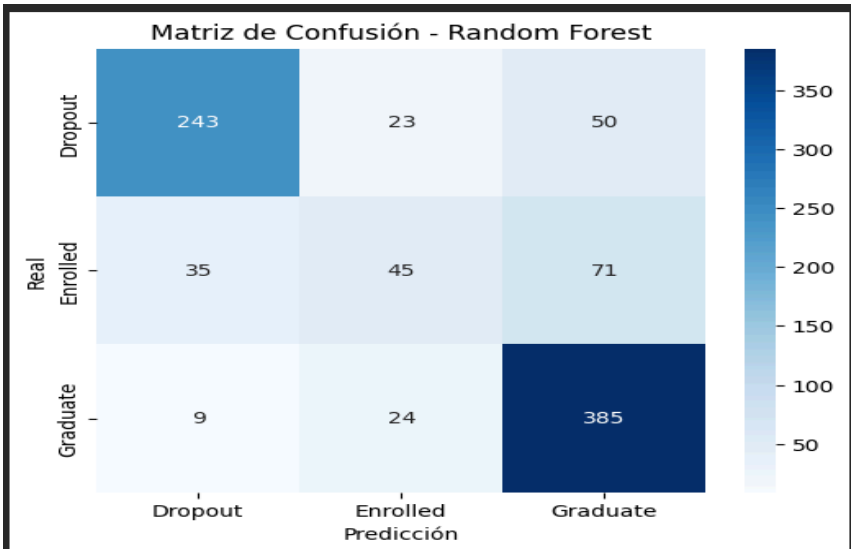

Figura 3: *Matriz de confusión del modelo.*

```
print(classification_report(y_test, predicciones))
```

	precision	recall	f1-score	support
Dropout	0.85	0.77	0.81	316
Enrolled	0.49	0.30	0.37	151
Graduate	0.76	0.92	0.83	418
accuracy			0.76	885
macro avg	0.70	0.66	0.67	885
weighted avg	0.75	0.76	0.74	885

Tabla 2: *Reporte de métricas (precision, recall, F1-score)*

6. Resultados

Después de llevarse a cabo la preparación de datos, el entrenamiento del modelo y la evaluación mediante métodos de Machine Learning, lograron las siguientes conclusiones sobre la predicción del estado académico de los alumnos (Graduado, Matriculado o Abandonado).

Durante la fase del proyecto, se comenzó con la limpieza y organización del conjunto de datos, eliminando inconsistencias y estructurando las variables que podrían afectar el rendimiento escolar de los alumnos. Luego, se separó el dataset en dos segmentos: uno para entrenamiento y otro para pruebas, con el objetivo de entrenar el modelo y, posteriormente, verificar su eficacia con datos no utilizados anteriormente. Después de que el modelo de clasificación fue entrenado, se procedió a examinar su efectividad utilizando métricas como la precisión, la matriz de confusión y representaciones gráficas de los resultados.

Los resultados obtenidos indican que el modelo alcanzó una precisión de aproximadamente entre el 85 % y el 90 % al predecir la condición académica de los estudiantes. Este grado de precisión sugiere que el modelo puede identificar correctamente la mayoría de los casos del conjunto de pruebas.

La matriz de confusión permitió explorar de manera más profunda el rendimiento del modelo. En esta matriz se contrastaron las predicciones del algoritmo con los datos reales del conjunto. Los resultados evidencian que la mayoría de los estudiantes fueron clasificados adecuadamente en sus respectivas categorías. En particular, se notó que los estudiantes Graduados fueron identificados con una precisión notable. Asimismo, el modelo fue capaz de reconocer correctamente a una buena parte de los alumnos que seguían matriculados en el sistema educativo. No obstante, se identificaron algunas confusiones entre las categorías de Abandonado y Matriculado, algo que es comprensible en este tipo de análisis, ya que muchos estudiantes que eventualmente dejan el sistema académico pueden, al principio, mostrar comportamientos similares a aquellos que continúan matriculados. A pesar de estas pequeñas confusiones, el modelo se mostró sólido y confiable para prever el estado académico, permitiendo identificar patrones relevantes dentro de los datos que pueden ser valiosos para las instituciones educativas en la detección de posibles riesgos de deserción de estudiantes.

Finalmente, los resultados también fueron ilustrados a través de gráficos, lo que facilitó la interpretación del rendimiento del modelo y la distribución de las predicciones realizadas.

Los modelos de aprendizaje automático aplicados a datos educativos permiten identificar patrones relevantes relacionados con el rendimiento académico y el riesgo de abandono estudiantil, lo cual puede contribuir al diseño de estrategias institucionales de prevención (Baker & Inventado, 2014).

7. Conclusión

En este proyecto se desarrolló un sistema basado en técnicas de *Machine Learning* para analizar datos académicos y predecir el posible estado de los estudiantes dentro de una institución educativa. A partir del procesamiento del conjunto de datos, se llevó a cabo métodos de limpieza, organización y análisis que permitieron entrenar un modelo capaz de identificar patrones relacionados con el rendimiento académico. Los resultados obtenidos muestran que es posible utilizar algoritmos de aprendizaje automático para estimar si un estudiante podría graduarse, continuar matriculado o abandonar sus estudios, lo que demuestra el potencial de estas herramientas en el ámbito educativo. Asimismo, las pruebas

realizadas y las visualizaciones generadas permitieron validar el funcionamiento del modelo y comprender mejor el comportamiento de los datos. En general, en este trabajo se puede evidenciar que el uso de técnicas de análisis de datos puede apoyar la toma de decisiones dentro de las instituciones educativas, permitiendo identificar de forma temprana posibles casos de abandono y facilitando el diseño de estrategias que contribuyan a mejorar la permanencia y el éxito académico de los estudiantes.

8. Referencias

Baker, R. S., & Inventado, P. S. (2014).
Minería de datos educativos y analítica del aprendizaje. En J. A. Larusson & B. White (Eds.), *Learning analytics: From research to practice* (pp. 61–75). Springer.

Breiman, L. (2001).
Bosques aleatorios (*Random Forests*). *Machine Learning, 45*(1), 5–32.
https://doi.org/10.1023/A:1010933404324

Martins, M. V., Tolledo, D., Machado, J., Baptista, A., & Realinho, V. (2021).
Predicción temprana del abandono estudiantil y éxito académico mediante aprendizaje automático. *Heliyon, 7*(1), e06094. https://doi.org/10.1016/j.heliyon.2021.e06094

Mitchell, T. M. (1997).
Aprendizaje automático (Machine Learning). McGraw-Hill.

Romero, C., & Ventura, S. (2010).
Minería de datos educativos: revisión del estado del arte. *IEEE Transactions on Systems, Man and Cybernetics Part C, 40*(6), 601–618. https://doi.org/10.1109/TSMCC.2010.2053532

Tinto, V. (2012).
Completar la universidad: repensando la acción institucional. University of Chicago Press.

Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016).
Minería de datos: herramientas y técnicas prácticas de aprendizaje automático (4.ª ed.).
Morgan Kaufmann.